

Tutorial *Hive*

Instalação do Hive e Kick-off

Baseado no trabalho de Nikolay Dimolarov e Romain Rigaux

(https://towardsdatascience.com/making-big-moves-in-big-data-with-hadoop-hive-parquet-hue-and-docker-320a52ca175)

Preparar o Docker Hive

git clone https://github.com/tech4242/docker-hadoop-hive-parquet.git

cd .\docker-hadoop-hive-parquet\

docker-compose up -d

Nota: caso obtenha uma mensagem de erro no arranque, executar o comando:

net stop winnat

Importar dados de ficheiro Parquet

- 1. Seleccionar um dataset com informação interessante (e.g., Kaggle)
 - a. Para efeitos deste tutorial utilizar https://www.kaggle.com/datasets/samyakb/student-stress-factors/
- Descarregar o ficheiro "Student Stress Factors.csv" e renomear para "Student_Stress_Factors.csv"
- 3. Colocar esse ficheiro junto ao script "parquet_converter.py"
- 4. Modificar a linha 8 colocando o caminho correcto para o ficheiro
- 5. Modificar a linha 9 colocando o caminho pretendido para o ficheiro de destino
- 6. Instalar os seguintes módulos Python:



```
pip install pandas
pip install pyarrow
```

7. Executar o script "parquet_converter.py" de modo a obter o ficheiro "Student_Stress_Factors.parquet"

Criar modelo de dados para suportar a integração

1. Instalar os seguintes módulos Python:

```
pip install parquet-tools
```

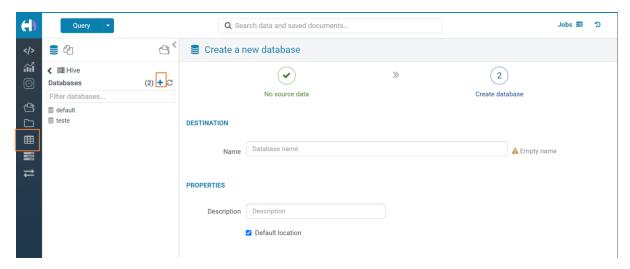
2. Executar o comando na directoria onde está o ficheiro "Student_Stress_Factors.parquet"

parquet-tools inspect .\Student_Stress_Factors.parquet

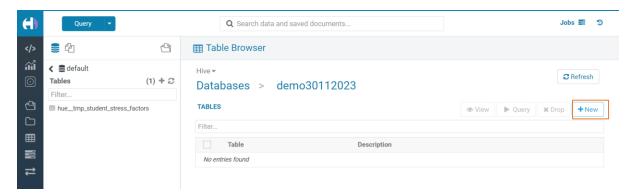
```
PS C:\Users\msi\docker-hadoop-hive-parquet> parquet-tools inspect .\Student_Stress_Factors.parquet
########### file meta data ###########
created_by: parquet-cpp-arrow version 14.0.1
num_columns: 7
num_rows: 53
num_row_groups: 1
format_version: 2.6
serialized_size: 6306
########### Columns ###########
Timestamp
Kindly Rate your Sleep Quality 😴
How many times a week do you suffer headaches @?
How would you rate you academic performance how would you rate your study load?
How many times a week you practice extracurricular activities 🥍?
How would you rate your stress levels?
########### Column(Timestamp) ###########
name: Timestamp
path: Timestamp
max_definition_level: 1
max_repetition_level: 0
physical_type: BYTE_ARRAY
logical_type: String
converted_type (legacy): UTF8
compression: UNCOMPRESSED (space_saved: 0%)
```

- 3. Aceder ao hue: http://localhost:8888
 - a. Definir a password no primeiro acesso
- 4. Criar uma base de dados

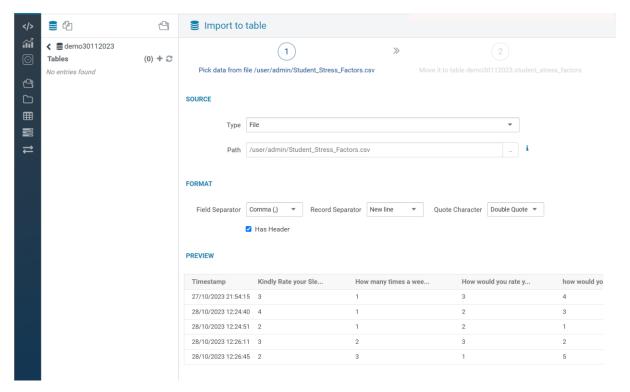




5. Criar uma nova tabela "demo30112023"



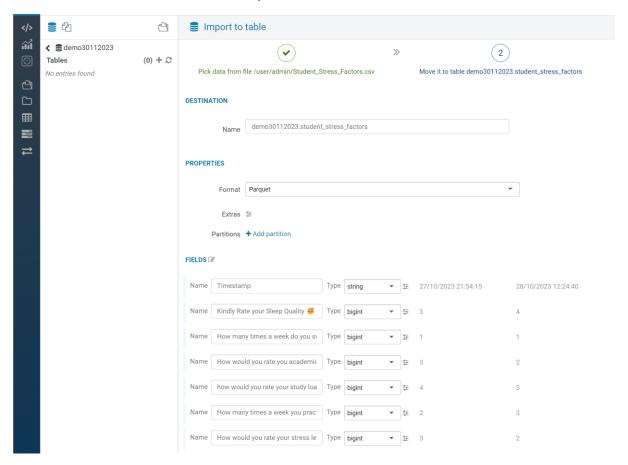
6. Importar os dados do ficheiro "csv" após realizar o upload



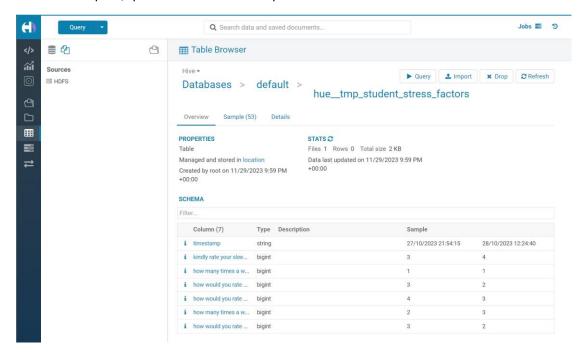
7. Seleccionar o nome da tabela e o formato "csv" do ficheiro



8. Seleccionar o destino como "Parquet"

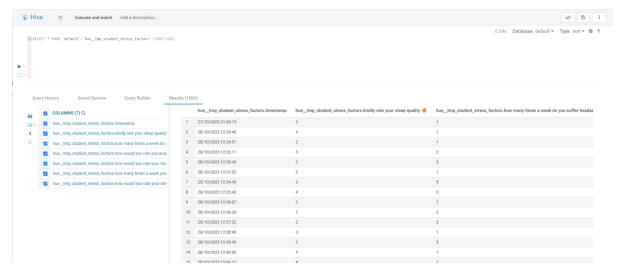


- 9. Submit
- 10. Esta versão utiliza Hive-on-MR (Hive on MapReduce) que foi descontinuado. As alternativas são Spark, que será introduzido na próxima UC.





11. Visualizar os dados através do *dashboard* e realizar algumas *queries* sobre os novos dados. **Dica:** faça primeiro uma query e depois mude para o gráfico



12. Podemos tirar algumas conclusões com os dados?

